

4 Стандартизированное уравнение множественной линейной регрессии. Частные уравнения регрессии

4.1 Теоретическое введение

Линейное уравнение множественной регрессии в виде $\hat{y}(x) = b_0 + b_1x_1 + b_2x_2 + \dots + b_mx_m$ называют уравнением в натуральном масштабе.

Другой вид уравнения множественной регрессии – уравнение регрессии в стандартизированном масштабе:

$$t_y = \beta_1 t_{x_1} + \beta_2 t_{x_2} + \dots + \beta_m t_{x_m},$$

где $t_y = \frac{y - \bar{y}}{\sigma_y}$, $t_{x_i} = \frac{x_i - \bar{x}_i}{\sigma_{x_i}}$ – стандартизированные переменные;

β_i – стандартизированные коэффициенты регрессии.

Одним из плюсов уравнения в стандартизированном масштабе является возможность ранжировать факторы по силе влияния на результат y , исходя из величин стандартизированных коэффициентов. Чем больше по модулю величина коэффициента, тем сильнее соответствующий фактор влияет на результат.

К уравнению множественной регрессии в стандартизированном масштабе применим МНК. Стандартизированные коэффициенты регрессии (β -коэффициенты) определяются из следующей системы уравнений

$$\begin{cases} r_{yx_1} = \beta_1 + \beta_2 r_{x_1x_2} + \beta_3 r_{x_1x_3} + \dots + \beta_m r_{x_1x_m}, \\ r_{yx_2} = \beta_1 r_{x_2x_1} + \beta_2 + \beta_3 r_{x_2x_3} + \dots + \beta_m r_{x_2x_m}, \\ \Lambda \\ r_{yx_m} = \beta_1 r_{x_mx_1} + \beta_2 r_{x_mx_2} + \beta_3 r_{x_mx_3} + \dots + \beta_m, \end{cases}$$

где r_{yx_i} – парные коэффициенты корреляции.

Связь коэффициентов множественной регрессии b_i со стандартизированными коэффициентами β_i описывается соотношением

$$b_i = \beta_i \frac{\sigma_y}{\sigma_{x_i}}.$$

Параметр a определяется как

$$a = \bar{y} - b_1\bar{x}_1 - b_2\bar{x}_2 - \dots - b_m\bar{x}_m.$$

Средние коэффициенты эластичности для линейной регрессии показывают, на сколько процентов в среднем изменится результат от своей средней величины, если фактор изменится на 1% от своего среднего значения, и рассчитываются по формуле

$$\bar{\varepsilon}_{yx_i} = b_i \frac{\bar{x}_i}{\bar{y}}.$$

Индекс множественной корреляции для уравнения в стандартизированном масштабе можно определить по формуле

$$R = \sqrt{\sum_{i=1}^m \beta_i^2 r_{yx_i}^2}.$$

Качество построенной модели в целом оценивает коэффициент детерминации. Коэффициент множественной детерминации R^2 рассчитывается как квадрат индекса множественной корреляции.

Скорректированный коэффициент множественной детерминации содержит поправку на число степеней свободы и рассчитывается по формуле

$$\bar{R}^2 = 1 - (1 - R^2) \frac{n - 1}{n - m - 1},$$

где n – число наблюдений; m – число факторов.

Ранжировать факторы можно также с помощью частных коэффициентов корреляции. Частные коэффициенты корреляции характеризуют тесноту связи между результатом и соответствующим фактором при устранении влияния других факторов, включенных в уравнение регрессии. Частные коэффициенты корреляции, так же как и парные, изменяются в пределах от -1 до $+1$.

Для уравнения регрессии с двумя факторами частные коэффициенты корреляции находятся по формулам

$$r_{yx_1 \cdot x_2} = \frac{r_{yx_1} - r_{yx_2} \cdot r_{x_1 x_2}}{\sqrt{(1 - r_{yx_2}^2)(1 - r_{x_1 x_2}^2)}},$$

$$r_{yx_2 \cdot x_1} = \frac{r_{yx_2} - r_{yx_1} \cdot r_{x_1 x_2}}{\sqrt{(1 - r_{yx_1}^2)(1 - r_{x_1 x_2}^2)}},$$

$$r_{x_1 x_2 \cdot y} = \frac{r_{x_1 x_2} - r_{yx_1} \cdot r_{yx_2}}{\sqrt{(1 - r_{yx_1}^2)(1 - r_{yx_2}^2)}}.$$

На основе линейного уравнения множественной регрессии могут быть найдены частные уравнения регрессии, которые связывают результативный признак y с соответствующим фактором x_i при закреплении других факторов на среднем уровне.

Для сравнения уравнений регрессии можно воспользоваться частными F -критериями.

Частный F -критерий F_{x_i} оценивает статистическую значимость добавления фактора x_i в уравнение множественной регрессии, то есть оценивает целесообразность включения в уравнение фактора x_i после того, как в него были включены остальные факторы.

Для уравнения регрессии с двумя факторами частные F -критерии находятся по формулам

$$F_{x_1 \text{ факт}} = \frac{R^2 - r_{yx_2}^2}{1 - R^2} \cdot (n - m - 1),$$

$$F_{x_2 \text{ факт}} = \frac{R^2 - r_{yx_1}^2}{1 - R^2} \cdot (n - m - 1).$$

Фактическое значение частного F -критерия сравнивается с табличным $F_{\text{табл}}(\alpha, v_1, v_2)$, где α – требуемый уровень значимости, $v_1 = 1$, $v_2 = n - m - 1$.

Если $F_{\text{табл}} < F_{x_i \text{ факт}}$, то дополнительное включение в модель фактора x_i статистически оправданно.

Частные F -критерии Фишера связаны со значениями t -критерия Стьюдента для соответствующего коэффициента регрессии линейного уравнения следующим образом $t_{b_i} = \sqrt{F_{x_i}}$.

4.2 Решение типовой задачи

4.2.1 Постановка типовой задачи

По 30 территориям РФ имеются данные, представленные в таблице 4.1.

Таблица 4.1 – Исходные данные задачи

Признак	Среднее значение	Среднеквадратическое отклонение	Линейный коэффициент парной корреляции
Среднедневной душевой доход, руб., y	86,8	11,44	$r_{x_1x_2} = -0,1160$
Среднедневная плата одного работающего, руб., x_1	54,9	5,86	$r_{yx_1} = 0,8405$
Средний возраст безработного, лет, x_2	33,5	0,58	$r_{yx_2} = -0,2101$

Требуется:

1) построить уравнение множественной регрессии в стандартизованной и естественной форме;

2) рассчитать средние частные коэффициенты эластичности, сравнить их со стандартизованными коэффициентами, пояснить различия между ними;

3) рассчитать линейные коэффициенты частной корреляции и коэффициент множественной корреляции, сравнить коэффициенты частной корреляции с линейными коэффициентами множественной корреляции, пояснить различия между ними;

4) рассчитать общий и частные F -критерии Фишера. Определить, какое уравнение лучше использовать для прогноза: парную регрессию y на x_1 , парную регрессию y на x_2 ; множественную регрессию.

4.2.2 Ход решения типовой задачи

1) Линейное уравнение множественной регрессии y от x_1 и x_2 имеет вид

$$y = a + b_1x_1 + b_2x_2.$$

Для расчета его параметров применим метод стандартизации переменных и построим искомое уравнение в стандартизованном масштабе

$$t_y = \beta_1t_{x1} + \beta_2t_{x2}.$$

Для нахождения стандартизованных коэффициентов β_1 и β_2 составим систему уравнений

$$\begin{cases} r_{yx_1} = \beta_1 + \beta_2 r_{x_1 x_2}, \\ r_{yx_2} = \beta_1 r_{x_2 x_1} + \beta_2. \end{cases}$$

Расчет β -коэффициентов выполним по формулам

$$\beta_1 = \frac{r_{yx_1} - r_{yx_2} r_{x_1 x_2}}{1 - r_{x_1 x_2}^2} = \frac{0,8405 - 0,2101 \cdot 0,116}{1 - 0,116^2} = \frac{0,8161}{0,9865} \approx 0,8273,$$

$$\beta_2 = \frac{r_{yx_2} - r_{yx_1} r_{x_1 x_2}}{1 - r_{x_1 x_2}^2} = \frac{-0,2101 + 0,8405 \cdot 0,116}{1 - 0,116^2} = \frac{-0,1126}{0,9865} \approx -0,1141.$$

Получим стандартизованное уравнение

$$t_y = 0,83 t_{x_1} - 0,11 t_{x_2}.$$

Для построения уравнения в естественной форме рассчитаем b_1 и b_2 , используя формулы для перехода от β_i к b_i

$$b_1 = \beta_1 \frac{\sigma_y}{\sigma_{x_1}} = \frac{0,8273 \cdot 11,44}{5,86} \approx 1,6150,$$

$$b_2 = \beta_2 \frac{\sigma_y}{\sigma_{x_2}} = \frac{-0,1141 \cdot 11,44}{0,58} \approx -2,2513.$$

Значение a определим из соотношения

$$a = \bar{y} - b_1 \cdot \bar{x}_1 - b_2 \cdot \bar{x}_2 = 86,8 - 1,6150 \cdot 54,9 + 2,2513 \cdot 33,5 \approx 73,5545.$$

Уравнение множественной регрессии в естественной форме

$$y = 73,55 + 1,62x_1 - 2,25x_2.$$

2) Для характеристики относительной силы влияния x_1 и x_2 на y рассчитаем средние коэффициенты эластичности

$$\bar{\epsilon}_{yx_1} = b_1 \frac{\bar{x}_1}{\bar{y}} = \frac{1,6150 \cdot 54,9}{86,8} \approx 1,0215\%,$$

$$\bar{\epsilon}_{yx_2} = b_2 \frac{\bar{x}_2}{\bar{y}} = \frac{-2,2513 \cdot 33,5}{86,8} \approx -0,8689\%.$$

С увеличением средней заработной платы x_1 на 1% от её среднего уровня средний душевой доход y возрастает на 1,02% от своего среднего уровня, при повышении среднего возраста безработного x_2 на 1% среднедушевой доход y снижается на 0,87% от среднего уровня. Очевидно, что сила влияния средней заработной платы x_1 на средний душевой доход y оказалась большей, чем сила влияния среднего возраста безработного x_2 . К аналогичным выводам о силе связи приходим при сравнении модулей значений β_1 и β_2

$$|\beta_1| = |0,8273| > |\beta_2| = |-0,1141|.$$

Различия в силе влияния фактора на результат, полученные при сравнении $\bar{\epsilon}_{yx_i}$ и β_i объясняются тем, коэффициент эластичности происходит из соотношения средних $\bar{\epsilon}_{yx_i} = b_i \frac{\bar{x}_i}{\bar{y}}$, а β -коэффициент – из соотношения средних

$$\text{квадратических отклонений } \beta_i = b_i \frac{\sigma_{x_i}}{\sigma_y}.$$

3) Рассчитаем линейные коэффициенты частой корреляции

$$r_{y_{x_1} \cdot x_2} = \frac{r_{yx_1} - r_{yx_2} \cdot r_{x_1 x_2}}{\sqrt{(1-r_{yx_2}^2)(1-r_{x_1 x_2}^2)}} = \frac{0,8405 - 0,2101 \cdot 0,116}{\sqrt{(1-0,2101^2)(1-0,116^2)}} \approx 0,8404,$$

$$r_{y_{x_2} \cdot x_1} = \frac{r_{yx_2} - r_{yx_1} \cdot r_{x_1 x_2}}{\sqrt{(1-r_{yx_1}^2)(1-r_{x_1 x_2}^2)}} = \frac{-0,2101 + 0,8405 \cdot 0,116}{\sqrt{(1-0,8405^2)(1-0,116^2)}} \approx -0,2092,$$

$$r_{x_1 x_2 \cdot y} = \frac{r_{x_1 x_2} - r_{yx_1} \cdot r_{yx_2}}{\sqrt{(1-r_{yx_1}^2)(1-r_{yx_2}^2)}} = \frac{-0,116 + 0,8405 \cdot 0,2101}{\sqrt{(1-0,8405^2)(1-0,2101^2)}} \approx 0,1093.$$

Значения коэффициентов парной и частной корреляции из-за слабой межфакторной связи ($r_{x_1 x_2} = -0,1160$) отличаются незначительно: выводы о тесноте и направлении связи на основе коэффициентов парной и частной корреляции совпадают

$$r_{yx_1} = 0,8405; \quad r_{yx_2} = -0,2101; \quad r_{x_1 x_2} = 0,1160;$$

$$r_{y_{x_1} \cdot x_2} = 0,8404; \quad r_{y_{x_2} \cdot x_1} = -0,2092; \quad r_{x_1 x_2 \cdot y} = 0,1093.$$

Вычислим линейный коэффициент множественной корреляции

$$R = \sqrt{r_{yx_1}^2 \beta_1 + r_{yx_2}^2 \beta_2} = \sqrt{0,8405^2 \cdot 0,8273 + 0,2101^2 \cdot 0,1141} = \sqrt{0,7193} \approx 0,8481.$$

Коэффициент детерминации равен $R^2 \approx 0,7193$.

Зависимость y от x_1 и x_2 характеризуется как тесная, в которой 72% вариации среднего душевного дохода определяются вариацией учтённых в модели факторов: средней заработной платы и среднего возраста безработного. Прочие факторы, не включённые в модель, составляют соответственно 28% от общей вариации y .

4) Общий F -критерий проверяет гипотезу H_0 о статистической незначимости уравнения регрессии и показателя тесноты связи

$$F_{\text{факт}} = \frac{R^2}{1-R^2} \cdot \frac{n-m-1}{m} = \frac{0,7193}{0,2807} \cdot \frac{27}{2} \approx 34,59,$$

$$F_{\text{табл}}(\alpha, m, n-m-1) = F_{\text{табл}}(0,05; 2; 27) = 3,35.$$

Сравнивая $F_{\text{факт}}$ и $F_{\text{табл}}$, приходим к выводу о необходимости отклонить гипотезу H_0 , так как $F_{\text{табл}} < F_{\text{факт}}$. С вероятностью $1 - \alpha = 0,95$ делаем заключение о статистической значимости уравнения в целом и показателя тесноты связи R , которые сформировались под неслучайным воздействием факторов x_1 и x_2 .

Вычислим частные F -критерии

$$F_{x_1 \text{ факт}} = \frac{R^2 - r_{yx_2}^2}{1-R^2} \cdot \frac{n-m-1}{1} = \frac{0,8481^2 - 0,2101^2}{1-0,8481^2} \cdot \frac{30-2-1}{1} \approx 64,94,$$

$$F_{x_2 \text{ факт}} = \frac{R^2 - r_{yx_1}^2}{1-R^2} \cdot \frac{n-m-1}{1} = \frac{0,8481^2 - 0,8405^2}{1-0,8481^2} \cdot \frac{30-2-1}{1} \approx 1,24,$$

$$F_{\text{табл}}(\alpha, m, n-m-1) = F_{\text{табл}}(0,05; 1; 27) = 4,21.$$

Сравнивая $F_{x_1 \text{ факт}}$ и $F_{\text{табл}}$, приходим к выводу о целесообразности включения в модель фактора x_1 после фактора x_2 , так как $F_{x_1 \text{ факт}} > F_{\text{табл}}$.

Сравнивая $F_{x_2 \text{ факт}}$ и $F_{\text{табл}}$, приходим к выводу о нецелесообразности включения в модель фактора x_2 после фактора x_1 , так как $F_{x_2 \text{ факт}} < F_{\text{табл}}$.

Это означает, что парная регрессионная модель зависимости среднего дохода от средней заработной платы является достаточно статистически значимой, надёжной и что нет необходимости улучшать её, включая дополнительный фактор x_2 (средний возраст безработного).

4.3 Задачи для самостоятельного решения

Вариант 1

По совокупности 30 предприятий концерна изучается зависимость прибыли y (тыс. руб.) от выработки продукции на одного работника x_1 (ед.) и индекса цен на продукцию x_2 (%):

Признак	Среднее значение	Среднеквадратическое отклонение	Парный коэффициент корреляции
y	250	38	$r_{x_1 x_2} = 0,42$
x_1	47	12	$r_{yx_1} = 0,68$
x_2	112	21	$r_{yx_2} = 0,63$

Требуется:

- 1) построить линейные уравнения парной регрессии, оценить их значимость с помощью F -критерия Фишера;
- 2) найти уравнение множественной регрессии в стандартизованном и натуральном масштабе;
- 3) рассчитать множественный коэффициент корреляции, общий и частный критерии Фишера и сделать выводы.

Вариант 2

По данным 20 территорий страны изучается зависимость урожайности зерновых y (ц/га) от количества осадков в период вегетации x_1 (мм) и средней температуры воздуха x_2 (°C):

Признак	Среднее значение	Среднеквадратическое отклонение	Парный коэффициент корреляции
y	21	11	$r_{x_1 x_2} = -0,42$
x_1	270	64	$r_{yx_1} = 0,49$
x_2	14	4	$r_{yx_2} = 0,43$

Требуется:

- 1) построить линейные уравнения парной регрессии, оценить их значимость с помощью F -критерия Фишера;
- 2) найти уравнение множественной регрессии в стандартизованном и натуральном масштабе;
- 3) рассчитать множественный коэффициент корреляции, общий и частный критерии Фишера и сделать выводы.

Вариант 3

По 30 заводам, выпускающим продукцию А, изучается зависимость потребления электроэнергии y (тыс. кВт/ч) от производства продукции – x_1 (тыс. ед.) и уровня механизации – x_2 (%):

Признак	Среднее значение	Среднеквадратическое отклонение	Парный коэффициент корреляции
y	1000	27	$r_{x_1x_2} = 0,38$
x_1	420	45	$r_{yx_1} = 0,77$
x_2	41,5	18	$r_{yx_2} = 0,43$

Требуется:

- 1) построить уравнение множественной регрессии в стандартизованном и натуральном масштабе;
- 2) определить показатели частной и множественной корреляции;
- 3) найти частные коэффициенты эластичности и сравнить их с β -коэффициентами;
- 4) рассчитать общий и частные критерии Фишера и сделать выводы.

Вариант 4

По 25 предприятиям концерна изучается зависимость потребления материалов y (т) от энерговооруженности труда x_1 (кВт/ч на одного рабочего) и объема произведенной продукции x_2 (тыс. ед.):

Признак	Среднее значение	Среднеквадратическое отклонение	Парный коэффициент корреляции
y	1000	27	$r_{x_1x_2} = 0,38$
x_1	420	45	$r_{yx_1} = 0,77$
x_2	41,5	18	$r_{yx_2} = 0,43$

Требуется:

- 1) построить уравнение множественной регрессии в стандартизованном и натуральном масштабе;
- 2) определить показатели частной и множественной корреляции;
- 3) найти частные коэффициенты эластичности и сравнить их с β -коэффициентами;
- 4) рассчитать общий и частные критерии Фишера и сделать выводы.

Вариант 5

Имеется информация по 25 наблюдениям:

Признак	Среднее значение	Коэффициент вариации, %	Уравнение регрессии
y	35	20	$\hat{y} = 20 + x_1 - 2x_2$
x_1	16	30	$\hat{y} = 9 + 1,1x_1$
x_2	8	10	$\hat{y} = 4 - 4,1x_2$

Требуется:

- 1) оценить значимость каждого уравнения регрессии, если известно, что $r_{x_1x_2} = -0,35$;
- 2) оценить значимость коэффициентов уравнения множественной регрессии;
- 3) определить показатели частной корреляции;
- 4) найти частные коэффициенты эластичности.

Вариант 6

Имеется информация по 22 наблюдениям:

Признак	Среднее значение	Коэффициент вариации, %	Уравнение регрессии
y	23	20	$\hat{y} = 19 - 2x_1 - 0,5x_2$
x_1	6	40	$\hat{y} = 9 - x_1$
x_2	8	10	$\hat{y} = 4 + 0,6x_2$

Требуется:

- 1) оценить значимость каждого уравнения регрессии, если известно, что $r_{x_1x_2} = -0,35$;
- 2) оценить значимость коэффициентов уравнения множественной регрессии;
- 3) найти скорректированный коэффициент множественной корреляции;
- 4) определить показатели частной корреляции.

Вариант 7

По 50 семьям изучалось потребление мяса y (кг на душу населения) от дохода x_1 (руб. на одного члена семьи) и от потребления рыбы x_2 (кг на душу населения):

Уравнение регрессии	$\hat{y} = -180 + 0,2x_1 - 0,4x_2$		
Стандартные ошибки параметров	20	0,01	0,25
Множественный коэффициент корреляции	0,85		

Требуется:

- 1) используя t -критерий Стьюдента, оценить значимость параметров уравнения;
- 2) рассчитать F -критерий Фишера;
- 3) оценить по частным F -критериям Фишера целесообразность включения в модель фактора x_1 после фактора x_2 и фактора x_2 после фактора x_1 .

Вариант 8

По 25 торговым предприятиям изучалась зависимость валового дохода y (млн. руб.) от среднегодовой стоимости основных фондов x_1 (млн. руб.) и оборотных средств x_2 (млн. руб.):

Уравнение регрессии	$\hat{y} = 9,8 + 0,7x_1 + 0,8x_2$		
Стандартные ошибки параметров	45,6	0,8	0,5
Множественный коэффициент корреляции	0,7		

Требуется:

- 1) используя t -критерий Стьюдента, оценить значимость параметров уравнения;
- 2) рассчитать F -критерий Фишера;
- 3) оценить по частным F -критериям Фишера целесообразность включения в модель фактора x_1 после фактора x_2 и фактора x_2 после фактора x_1 .

Вариант 9

По 40 предприятиям одной отрасли исследовалась зависимость производительности труда y от уровня квалификации рабочих x_1 и от энерговооруженности их труда x_2 :

Уравнение регрессии	$\hat{y} = a + 10x_1 + 2x_2$		
Стандартные ошибки параметров	0,5	2	?
t -критерий для параметров	3	?	5
Множественный коэффициент корреляции	0,85		

Требуется:

- 1) определить параметр a и заполнить пропущенные значения;
- 2) оценить значимость уравнения в целом, используя значение множественного коэффициента корреляции;
- 3) определить, какой из факторов оказывает более сильное воздействие на результат.

Вариант 10

По 30 предприятиям одной отрасли исследовалась зависимость объема выпуска продукции y (млн. руб.) от численности рабочих на предприятии x_1 (чел.) и от среднегодовой стоимости основных фондов x_2 (млн. руб.):

Уравнение регрессии	$\hat{y} = a + 0,48x_1 + 20x_2$		
Стандартные ошибки параметров	2	0,06	?
t -критерий для параметров	1,5	?	4
Множественный коэффициент корреляции	0,85		

Требуется:

- 1) определить параметр a и заполнить пропущенные значения;
- 2) оценить значимость уравнения в целом, используя значение множественного коэффициента корреляции;
- 3) построить доверительные интервалы для коэффициентов регрессии с вероятностью 0,95.